

MBSC-Net:面向多模态虚假新闻检测的 互补多分支语义对比网络

摘要: 社交媒体虚假新闻检测的核心挑战在于如何全面捕捉文本与视觉模态间复杂多样的跨模态语义关系。现有方法多采用单分支融合策略,难以同时建模乘性交互、细粒度对齐与自适应模态加权,导致信息丢失与模态偏差。针对上述问题,本文提出MBSC-Net,一种基于互补多分支并行融合与语义对比优化的多模态虚假新闻检测框架。该框架构建了由双线性池化、跨模态投影注意力和级联自适应模态门控组成的三分支融合架构,三条通路在功能上相互补充,共同形成对跨模态语义关系的多粒度表征。融合后的特征经轻量级2层Transformer语义编码器进行深层上下文精炼,并通过联合优化交叉熵分类损失和有监督对比损失的多目标训练策略进行学习。在Weibo、Weibo21和Pheme三个公开数据集上的实验结果表明,MBSC-Net在F1分数上分别达到0.951、0.948和0.855,在多项评估指标上超越了近年八种主流基线模型。验证了其在虚假新闻检测任务中的有效性。源代码已开源至<https://github.com/xufeimao0-eng/MBSC-Net>。

关键词: 虚假新闻检测; 多模态融合; 跨模态注意力; 对比学习

1 引言

在数字时代,社交媒体平台已成为公众获取信息的主要渠道,其快速增长改变了信息的创造与传播方式。微博、Twitter和Facebook等平台在促进实时信息交流的同时,也为虚假新闻的大规模传播提供了便利条件[1]。虚假新闻的负面影响极为广泛且十分迅速,给社会舆论环境造成负面影响[2]。

因此,自动虚假新闻检测已成为一项关键的研究挑战。早期方法主要依赖文本特征[3],但社交媒体内容的多模态特性促使研究者转向视觉-语言联合建模方法[4]。近年来,BERT[5]和CLIP[6]等预训练模型的出现,为从文本和图像中提取丰富的语义特征提供了强大的技术支撑,显著提升了多模态虚假新闻检测的性能上限。

尽管现有方法已取得长足进步,但多模态虚假新闻检测仍面临三个核心挑战。第一,浅层融合与局部交互导致的表示局限。目前主流的多模态检测方法中,EANN[7]的事件对抗训练主要学习跨事件的共享文本特征,而SAFE[8]的跨模态相似度计算仅度量全局余弦相似度,这些单维度交互机制对细粒度语义错位(如图中特定物体与文本描述的局部矛盾)和模态间动态贡献差异(如以图为主与以文为主的帖子)的捕捉能力有限。具体而言,现有单分支注意力机制如HMCAN[9]擅长捕获文本词与图像区域的局部对齐,但在建模全局乘性不一致和自适应模态均衡方面存在固有局限。第二,特征空间的判别优化不足。单分类损失仅关注决策边界的优化,缺乏对跨模态语义一致性和类内特征紧凑性的显式约束,导致所学表示的判别能力有限。

针对以上挑战,本文提出MBSC-Net (Multi-Branch Semantic Contrasting Network),一种互补多分支语义对比网络。该网络的核心设计理念在于:不同类型跨模态交互的互补性建模是提升检测鲁棒性的关键。具体而言,MBSC-Net将双线性池化、跨模态投影注意力和级联自适应模态门控三条通路并行集成于统一的融合管道。融合后的多模态表示通过

轻量级Transformer语义编码器[10]进一步精炼，捕获特征空间中的高阶上下文依赖。训练阶段采用多目标联合优化策略：以带标签平滑的交叉熵损失作为主分类信号和有监督对比损失作为辅助正则化信号[11]，从分类准确性和类内紧凑性两个维度协同优化模型。

本文的主要贡献总结如下：

(1).提出互补三支融合架构。将双线性池化、跨模态投影注意力和级联自适应模态门控三种功能互补的融合机制统一于并行架构，实现对乘性交互、语义激活和模态权重三种跨模态关系的多粒度联合建模，有效克服了单分支融合策略的信息丢失问题。

(2).设计语义对比优化框架。在融合后引入轻量级Transformer语义编码器对融合特征进行深层上下文精炼，并构建了融合分类损失和有监督对比损失的多目标联合训练框架。其中，分类损失确保类别判别能力，有监督对比损失提升类内特征紧凑性，两者从互补角度协同优化表示质量。

2 相关工作

2.1 基于文本的虚假新闻检测

早期虚假新闻检测主要依赖文本内容的单模态分析。传统方法通过提取写作风格、情感倾向、词法特征等语言学信号，结合SVM[12]、决策树[13]等经典机器学习分类器进行真伪判别。随着深度学习技术的兴起，基于RNN[14]、CNN[15]的模型被广泛应用于捕捉新闻文本中的时序依赖和局部语义模式，显著提升了文本特征的自动提取能力。近年来，以BERT、RoBERTa[16]为代表的大规模预训练语言模型通过在海量通用语料上的自监督预训练，学习到了丰富的语言知识表示，仅需少量领域数据的微调即可在虚假新闻检测任务上取得优异性能。中文场景下的BERT-base-Chinese[17]和英文场景下的BERT-base-Uncased[18]等模型同样展现出了强大的文本理解能力，为后续的多模态方法奠定了坚实基础。然而，纯文本方法忽略了社交媒体新闻的视觉维度。虚假新闻的制造者往往精心选择或篡改图像以增强内容的可信度或煽动性，图像中蕴含的语义信息对于准确判别真伪至关重要，这使得多模态联合建模成为该领域发展的必然趋势。

2.2 多模态虚假新闻检测

社交媒体新闻的多模态特性推动了多模态检测方法的发展。EANN:引入对抗神经网络，通过梯度反转层学习事件不变特征，减少对特定事件的过拟合。SpotFake[19]：提出将BERT和VGG-19[20]提取的文本和视觉特征进行简单的拼接融合。SAFE利用文本和图像表示之间的余弦相似度作为辅助信号，证明跨模态相似度有助于检测。HMCAN设计了分层共注意力网络，通过双向注意力机制捕捉文本词和图像区域之间的细粒度交互。MDFEND[21]通过混合专家模型引入多领域虚假新闻检测框架，建模领域特定和领域共享特征。BMR[22]提出基于改进混合专家(iMMoE)的多视角引导表示方法，使用Sigmoid门控而非Softmax以允许多个专家同时激活。MMDFND[23]设计了枢轴Transformer架构聚合跨模态信息。C3N[24]提出内容一致性卷积网络，用于捕捉局部跨模态不一致。

尽管上述方法在各自方向上取得了进展，但深入分析可以发现两个普遍存在的局限。一方面，大多数方法采用单分支融合策略或依赖简单拼接，或仅使用注意力

机制，难以同时捕捉模态间乘性交互、细粒度对齐与动态权重调制等多种类型的跨模态关系。另一方面，现有方法的训练目标通常局限于分类准确性，缺乏对跨模态语义对齐和特征空间结构的显式优化约束。本文提出的MBSC-Net正是针对这两个局限性，通过互补三分支架构与多目标对比优化框架进行系统性改进。

2.3 多分支融合与对比学习

多分支融合策略在视觉问答和图像与文本检索[25]等领域已被广泛验证有效[26]，其背后的核心思想在于：双线性池化擅长捕捉模态间的二阶乘性交互以揭示细微的语义不一致，注意力机制能够建模视觉与文本元素间的语义对齐关系，门控机制则提供了根据输入信息质量自适应调制各模态贡献的能力。在双线性融合的工程实现方面，Fukui等[27]提出了紧凑双线性池化(MCB)，利用Count Sketch投影将外积的高维映射降至对数级复杂度；Keto等[28]设计了低秩双线性注意力，通过因子分解避免了全外积的显式计算；Yu等[29]进一步提出深度模块化共注意力网络，实现了注意力与双线性交互的有效结合。

对比学习作为自监督表示学习的重要范式，以SimCLR[30]和CLIP为代表，已被证明能够产生高度判别性的特征表示。在多目标优化方面，PCGrad[31]和GradVac[32]等理论工作表明，当多个损失函数的梯度方向在参数空间中呈正交或互补分布时，联合优化不会产生有害的梯度冲突，并通过梯度余弦相似度分析验证了这一条件在MBSC-Net中的满足性。在虚假新闻检测领域，受SARD[33]和BC-FND[34]等的启发，本文将跨模态对齐损失与有监督对比损失作为辅助训练信号纳入优化框架，构建了多层次表示学习体系。

3 方法

3.1 总体架构

MBSC-Net的整体架构如图1所示，由四个核心模块协同构成。(1)文本和图像特征提取模块；(2)互补多分支融合管道。并行运行双线性融合、跨模态投影注意力和级联自适应模态门控三条通路；(3)语义编码器。通过轻量级2层Transformer对融合表示进行深层上下文精炼；(4)多目标训练框架。联合优化分类和对比两个互补损失函数。




图1 MBSC-Net整体框架图

3.2 文本和图像特征提取

3.2.1 文本特征提取

本文使用BERT预训练模型作为文本特征提取器。对于长度为 n 的新闻文本 $Text=[x_1, x_2, \dots, x_n]$ ，首先开展分词预处理，并遵循BERT的输入规范完成序列构造，生成词元序列 $Tokens=[[CLS], t_1, t_2, \dots, t_n, [SEP]]$ ，其中 $[CLS]$ 为序列起始标识， $[SEP]$ 为序列分隔与终止标识。随后通过BERT嵌入层对上述词元序列进行初始编码，每个词元单元 t_i 的嵌入向量由词嵌入、位置嵌入与句子嵌入三部分融合生成，对应的计算表达式为：

$$e_i = BERTEmbedding(t_i, P_i, s_i) \quad (1)$$

其中 t_i 为输入词元单元， P_i 表示该词元在序列中的位置索引， s_i 对应该词元所属的句子类别。经嵌入层计算后，得到完整的输入嵌入序列 $E=[e_{[CLS]}, e_1, e_2, \dots, e_{[SEP]}]$ 。最后，将处理后的文本序列 E 输入BERT预训练模型，提取文本特征向量 Z_t 。

3.2.2 图像特征提取

本文使用CLIP ViT(Vision Transformer)[35]预训练模型完成图像端的特征提取。对于输入的 $H \times W \times 3$ 尺寸RGB图像，ViT首先对其进行分块切分，将整幅图像拆解为若干个 $p \times p$ 大小的图像子块，并将每个图像块映射为一维特征向量形式。记第 i 个图像块对应的初始特征向量为 x_i ，其对应的可学习位置嵌入向量为 p_i ；为保留图像的空间位置信息，将位置嵌入与图像块特征逐元素相加，得到融合位置信息的特征表示 $x'_i = x_i + p_i$ 。之后将处理后的图像块特征序列输入Transformer编码器中进行深层特征编码，最终输出全局图像特征向量 Z_v 。

Transformer编码器主要由多头自注意力层与前馈神经网络层堆叠构成。其中多头自注意力层用于计算每个图像块与全局所有图像块之间的关联权重，以此建模长距离像素依赖关系，并输出每个图像块的加权融合特征，计算过程可表示为：

$$Attention(x'_i) = \text{softmax}\left(\frac{x'_i W_Q (x'_i W_K)^T}{\sqrt{d_k}}\right) (x'_i W_V) \quad (2)$$

其中 W_Q 、 W_K 、 W_V 分别为查询、键、值三路对应的可学习权重矩阵， d_k 为单个注意力头的特征维度，用于对注意力得分进行尺度归一化，避免内积值过大导致softmax函数梯度饱和。前馈神经网络层串联于每一层注意力模块之后，对每个图像块的特征独立执行非线性变换，进一步增强特征的判别能力。最终对Transformer编码器输出的全部图像块特征进行全局聚合，得到整幅图像的全局特征向量 Z_v ，计算公式如下：

$$Z_v = \sum_{i=1}^N FFN\left(Attention(x'_i)\right) \quad (3)$$

式中 N 代表图像分块的总数量，FFN对应前馈神经网络层的非线性变换操作。

3.3 多分支融合管道

多分支融合管道是MBSC-Net的核心部分，其设计遵循互补性优于单一性的原则。管道由三条功能互补的并行通路构成，分别从乘性二阶交互、跨模态语义激活和自适应模态均衡三个维度捕捉跨模态关系。

3.3.1 双线性融合分支

双线性分支捕捉模态间的乘性二阶交互，能够有效揭示语义不一致性。通过两个独立的线性投影矩阵 W_v 和 W_t ，将视觉特征 Z_v 和文本特征 Z_t 分别映射到公共特征空间。随后计算两个投影后向量的逐元素乘积(哈达玛积 $\odot$)，得到乘性交互特征向量，该特征编码了两类特征对应维度的乘性关联信息。接着通过线性投影矩阵 W_b 对交互特征进行信息整合与维度映射，得到融合特征。最后，应用层归一化 $\text{LayerNorm}(\cdot)$ [36] 操作，稳定训练过程并加速模型收敛。其双线性融合分支输出特征向量为 $h_{bilinear}$ 。

$$h_{bilinear} = \text{LayerNorm}(W_b \cdot (W_v z_v \odot W_t z_t)) \quad (4)$$

经计算，该逐元素乘积式双线性分支的总参数量约为1.05M；在V100-SXM2-16 GB的硬件环境下，单样本前向传播中逐元素乘性交互的显存开销约为2KB(float32精度)。对比采用全秩外积的基线双线性方案的总参数量约135.0M，单样本前向传播外积操作显存开销约1.05MB，总参数量与单样本显存开销均大幅降低。该实现方式避免了全秩外积方案中全参数张量带来的计算与存储负担，在保留乘性二阶交互建模能力的同时，将参数量与计算复杂度控制在可接受范围内。

类似的张量融合策略在视觉问答和多模态表示学习中已有成熟应用[37]，理论分析与实践均表明该方法能够有效捕捉成对乘性交互项[38]。

3.3.2 跨模态注意力特征融合分支

跨模态注意力分支建立从视觉特征到文本特征的注意力机制，使视觉表示能够主动激活与之语义相关的文本信息。与标准的多头自注意力[39]不同，本文采用的投影注意力在特征级别而非令牌级别进行操作，以适配编码器输出的全局单向量表示。

首先，将视觉特征和文本特征通过独立的线性投影映射至公共空间。随后，通过三个独立的投影矩阵将投影后的视觉特征映射为查询向量 Q ，文本特征映射为键向量 K 和值向量 V 。再计算缩放点积注意力 a ，其中缩放因子 $\sqrt{d_k}$ 用于防止点积值过大导致softmax梯度消失。

$$a = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (5)$$

为增强注意力的鲁棒性并保留原始视觉信息，引入可学习门控残差连接。设可学习标量参数 g ，通过sigmoid激活得到门控系数 $\gamma = \sigma(g) \in (0,1)$ ，该系数根据输入内容动态调制注意力表示与原始视觉特征的混合比例。其跨注意力融合分支输出特征向量为 h_{cross} 。

$$h_{cross} = \gamma \cdot a + (1 - \gamma) \cdot W_v z_v \quad (6)$$

3.3.3 模态门控分支

不同社交媒体帖子中，文本与视觉信息对真伪判别的贡献存在显著差异[40]。例如，纯文本谣言帖主要依赖文本语义进行判别，而图像篡改型虚假新闻则需要更多依赖视觉信息。为自适应地调制这种动态变化的模态贡献，本文设计了两级联动的自适应门控机制。

第一级：模态间门控。首先，通过语义投影网络 MLP_{sem} 对原始文本特征 Z_t 进行非线性变换，将其映射至与视觉特征兼容的统一隐空间，得到深层语义表示 t_{sem} 。

$$t_{sem} = MLP_{sem}(z_t) \quad (7)$$

该投影网络包含线性变换、层归一化、非线性激活与随机失活结构，用于完成文本特

征的空间对齐与语义增强。

随后，将投影后的视觉特征 $W_v z_v$ 与文本语义表示 t_{sem} 沿特征维度拼接，输入门控网络 MLP_{gate} 生成模态融合权重 α 。

$$\alpha = \sigma(MLP_{gate}([W_v z_v; t_{sem}])) \quad (8)$$

本部门控权重的生成同时依据两类特征信号：一是两类特征各自的绝对激活幅值，反映对应模态信息的整体显著性与判别置信度；二是两类特征在隐空间中的语义关联程度，由特征向量的空间夹角与内积关系决定，反映模态间信息的互补性与一致性。门控网络通过学习上述信号的联合非线性映射，输出取值范围为[0,1]的自适应权重。

基于门控权重 α ，对视觉特征与文本语义表示进行加权融合，得到第一级门控输出。

$$h_{gate}^{(l)} = \alpha \cdot W_v z_v + (1 - \alpha) \cdot t_{sem} \quad (9)$$

当 α 接近1时，模型更多依赖视觉信息；当 α 接近0时，模型更多依赖文本语义表示。

第二级：分支间门控。为进一步融合跨注意力分支与模态门控分支的互补信息，引入第二级门控机制，对两支路的输出特征进行二次自适应融合。

$$h_{gate} = \beta \cdot h_{cross} + (1 - \beta) \cdot h_{gate}^{(l)} \quad (10)$$

其中分支权重 β 的生成逻辑与 α 一致，以两支路输出的拼接特征为输入，通过同结构的门控网络学习得到。两级门控形成级联结构，可分别在模态层面与分支层面实现自适应权重分配，从不同粒度对多源特征进行融合优化，提升最终特征表示的判别能力。

在训练过程中，若某一模态或分支的损失梯度持续占优，门控权重易向该端极端倾斜，导致另一支路的特征被长期压制、对应参数无法得到有效更新，最终模型退化为单模态或单分支结构，陷入局部最优解[41]。为规避该问题，本文在总损失函数中引入门控分布正则化项，从两方面约束门控权重的训练过程。一方面为熵正则约束，对每一级门控权重 α 、 β 分别施加信息熵正则化，最大化权重的信息熵，避免权重过度趋近于0或1，保证训练过程中双模态、双分支均能获得有效激活与梯度更新。另一方面为均值中心约束，对每个训练批次内的门控权重均值施加中心约束，引导权重的整体期望维持在均衡区间，防止训练全程出现系统性的模态偏向。该正则化项与主任务分类损失以加权方式联合优化，在保留门控机制自适应融合能力的同时，有效提升了模型训练的稳定性，确保双模态特征均能充分参与真伪判别过程。

3.4 语义编码器

将双线性融合分支、跨注意力分支与模态门控分支的输出特征沿特征维度拼接后，通过两层结构的最终投影网络 MLP_{final} 映射至统一特征空间，得到全局融合特征 h_{fused} 。

$$h_{fused} = MLP_{final}([h_{bilinear}; h_{cross}; h_{gate}]) \quad (11)$$

该投影网络由线性变换、层归一化、GELU非线性激活与随机失活层依次堆叠构成，在完成特征空间对齐与规整的同时，依托中间层的非线性变换强化三条分支特征的交叉交互，使不同分支携带的互补判别信号在融合过程中相互增益，形成信息密度更高的紧凑融合表示。

为充分挖掘融合特征内部的高阶上下文依赖关系，进一步提升特征的判别能力，

本文引入轻量级Transformer结构作为语义编码器SemanticEncoder，对 h_{fused} 进行深层特征精炼。经语义编码器编码后的初始特征表示 X_0 计算公式如下：

$$X_0 = \text{SemanticEncoder}(h_{fused}) \quad (12)$$

Transformer的自注意力机制能够在融合特征空间中建模全局依赖关系，使每个特征维度能够感知并融合来自其他所有维度的上下文信息。相比直接将拼接特征送入分类器，语义编码器的引入为下游分类提供了上下文感知的丰富表示。

3.5 多目标训练

单一的分类损失仅关注决策边界优化，而无法保证特征表示的质量[42]。为同时提升分类准确性、跨模态语义一致性和特征判别能力，本文设计了多目标联合训练框架。

3.5.1 分类损失

采用带标签平滑的交叉熵损失 L_{CE} 作为主训练信号。设 $\epsilon=0.1$ 为平滑系数，平滑后的目标标签为 $\hat{y}_{i,c}=(1-\epsilon)y_{i,c}^{true}+\epsilon/2$ 。

$$L_{CE} = -\frac{1}{B} \sum_{i=1}^B \sum_{c=0}^I \tilde{y}_{i,c} \log \hat{y}_{i,c} \quad (13)$$

其中， B 为批次大小， $y_{i,c}$ 为模型对第 i 个样本属于类别 c 的预测概率。标签平滑将硬标签 $[0,1]$ 软化，能够降低模型对训练标签的置信度，从而增强泛化能力。

3.5.2 有监督对比损失

为进一步提升融合特征空间的判别能力，引入有监督对比学习。与无监督对比学习不同，有监督对比学习利用标签信息显式地构建正负样本对[43]，能够更有效地学习与下游任务相关的判别性特征。

首先，通过两层结构的投影网络 MLP_{proj} 对语义编码器输出的初始特征 X_0 进行非线性变换，将其映射至对比学习专用特征空间，再经 l_2 归一化处理后，得到样本 i 对应的对比特征向量 p_i 。

$$p_i = \ell_2 \left(MLP_{proj}(X_{0,i}) \right) \quad (14)$$

该投影网络由线性变换层与非线性激活层堆叠构成，用于完成特征空间的转换与适配。

对于批次内的每个锚点样本 i ，定义正样本集合 $P(i)=\{p \in \{1, \dots, B\} \mid \{i\}:y_p=y_i\}$ 由与样本 i 具有相同标签的所有其他样本构成；负样本集合为批次内除 i 自身外的所有其他样本。有监督对比损失的计算公式如下。

$$L_{CONT} = -\frac{1}{|P(i)|} \sum_{p \in P(i)} \log \frac{\exp(p_i \cdot p_p / \tau_c)}{\sum_{a \neq i} \exp(p_i \cdot p_a / \tau_c)} \quad (15)$$

其中， $\tau_c=0.1$ 为对比学习的温度参数， p_p 为正样本 p 的对比特征向量， p_a 为样本 a 的对比特征向量。

3.5.3 总体目标

最终的训练损失为上述两个损失函数的加权和 L_{TOTAL} 。

$$L_{TOTAL} = 0.6 \cdot L_{CE} + 0.4 \cdot L_{CONT} \quad (16)$$

其中交叉熵损失作为主损失，权重设为0.6，驱动分类决策边界优化。有监督对

比损失作为辅助正则化项，权重设为0.4，从类内特征紧凑性增强表示质量。二者功能互补，协同实现多模态表示学习。权重配置的选择基于两个数据集上的9组网格搜索实验。

4 实验

4.1 数据集

为保证实验的公平性与可行性，实验在多模态假新闻检测领域常用公开的数据集Weibo[7]、Weibo21[20]和PHEME[44]进行评估。将这三个数据集分别按7:1:2、8:1:1和6:2:2的比例随机划分为训练集、验证集和测试集。数据集都来自社交媒体平台，包括了真实新闻与虚假新闻的图文样本，各数据集统计信息如表1所示。

表1 数据集统计信息

数据集	真实新闻	虚假新闻	新闻总计	图片数量
Weibo	4779	4709	9488	8243
Weibo21	4640	4488	9128	9626
PHEME	1428	590	2018	2018

4.2 对照模型

为全面评估MBSC-Net的性能，将其与2018–2025年间八种具有代表性的多模态虚假新闻检测模型进行对比。EANN基于生成对抗网络，通过去除事件特定特征，保留跨事件共享特征来学习可区分的表示。SpotFake用BERT和VGG特征的简单拼接，配以浅层分类器。SAFE基于相似度感知的多模态融合，具有余弦相似度辅助损失。HMCAN使用分层共注意力网络，具有双向跨模态注意力。MDFEND基于混合专家的多领域虚假新闻检测，使用9个伪类别。BMR基于改进混合专家(iMMoE)的多视角引导表。MMDFND枢轴为Transformer，具有可学习的星型令牌进行跨模态聚合。C3N是内容一致性的卷积网络，使用图像块-文本令牌相似度矩阵和1D-CNN。

4.3 实验设置

实验在NVIDIA Tesla V100-SXM2-16GB GPU节点上开展。软件环境为Ubuntu 20.04、Python3.8.20、PyTorch1.9.1、CUDA10.2。训练配置为最大200轮，批量大小32，AdamW优化器(学习率 10^{-4} ，权重衰减 10^{-5})，余弦退火调度器($T_{max}=200$)，早停耐心值50轮，图像输入尺寸 224×224 。Weibo和Weibo21数据集采用BERT-base-Chinese预训练语言模型。PHEME数据集的预训练语言模型采用BERT-base-Uncased，CLIP模型的参数为避免过拟合而被冻结。

4.4 评估指标

本实验采用准确率(Acc)、精确率(Prec)、召回率(Rec)和F1分数。鉴于类别分布平衡，F1分数作为主要指标。统计显著性检验采用配对t检验(pairwise t-test)[45]在5次独立运行(不同随机种子)的结果上计算p值，以评估MBSC-Net相对次优基线的提升是否具有统计显著性。

4.5 对比实验

表2展示了MBSC-Net与所有基线模型在三个数据集上的全面比较。在Weibo、

Weibo21和PHEME数据集上的性能比较，其中最优结果以粗体标出。

表2 MBSC-Net与基线模型的对比实验结果

Datasets	Method	Acc	Prec	Rec	F1	P-value
Weibo	EANN	0.942	0.968	0.889	0.927	0.0062<0.01
	SpotFake	0.930	0.978	0.850	0.901	
	SAFE	0.943	0.946	0.913	0.930	
	HMCAN	0.937	0.972	0.872	0.919	
	MDFEND	0.933	0.930	0.928	0.916	
	BMR	0.945	0.952	0.913	0.932	
	M MDFND	0.940	0.962	0.889	0.924	
	C3N	0.913	0.952	0.829	0.887	
	MBSC-Net	0.960	0.972	0.930	0.951	
Weibo21	EANN	0.921	0.951	0.890	0.920	0.0012<0.01
	SpotFake	0.919	0.960	0.871	0.913	
	SAFE	0.925	0.958	0.890	0.923	
	HMCAN	0.933	0.926	0.941	0.934	
	MDFEND	0.931	0.926	0.938	0.932	
	BMR	0.917	0.967	0.864	0.913	
	M MDFND	0.928	0.934	0.922	0.928	
	C3N	0.912	0.947	0.874	0.909	
	MBSC-Net	0.948	0.951	0.945	0.948	
PHEME	EANN	0.888	0.824	0.788	0.805	0.00013<0.01
	SpotFake	0.883	0.789	0.805	0.802	
	SAFE	0.891	0.784	0.867	0.824	
	HMCAN	0.904	0.839	0.832	0.836	
	MDFEND	0.896	0.823	0.823	0.823	
	BMR	0.891	0.803	0.832	0.817	
	M MDFND	0.862	0.841	0.655	0.736	
	C3N	0.886	0.817	0.788	0.802	
	MBSC-Net	0.914	0.851	0.858	0.855	

表2的实验结果说明:MBSC-Net在Weibo、Weibo21、PHEME三个基准数据集的准确率与F1值均优于所有对比模型；在两个中文数据集上同时取得最优召回率，有效降低虚假新闻漏检风险。F1值较各数据集次优基线分别提升1.9、1.4、1.9个百分点，在精确率与召回率之间实现了更优的权衡。在事件异质性更强、分布更复杂的跨事件PHEME数据集上，模型仍保持显著性能优势，验证了其对不同语言、不同事件类型的社交媒体数据的良好适配能力。三组对比实验的P值均小于0.01，表明MBSC-Net的性能提升并非随机波动，实验结论具备统计学可靠性。

4.6 消融实验

为量化每个架构组件的贡献，在两个数据集上进行了六种变体的全面消融实验。Simple Concat是将完整的多分支融合管道替换为投影后图像和文本特征的简单拼接，无双线性、跨注意力、门控或语义编码器。SemanticEncoder为在简单拼接后接2层Transformer语义编码器，以隔离语义编码的效果。CE Only为仅使用交叉熵分类损失训练，其他部分完整。Ours Full为完整的MBSC-Net模型


表3 消融实验结果比较

Datasets	Variant	Acc	Prec	Rec	F1
Weibo	Simple Concat	0.940	0.956	0.897	0.917
	Semantic Encoder	0.941	0.960	0.893	0.925
	CE Only	0.946	0.963	0.906	0.944
	Ours(Full)	0.960	0.972	0.930	0.951
Weibo21	Simple Concat	0.920	0.957	0.881	0.917
	Semantic Encoder	0.925	0.926	0.926	0.925
	CE Only	0.912	0.957	0.864	0.931
	Ours(Full)	0.948	0.951	0.945	0.948
PHEME	Simple Concat	0.899	0.863	0.779	0.819
	Semantic Encoder	0.881	0.777	0.832	0.803
	CE Only	0.875	0.828	0.726	0.774
	Ours(Full)	0.914	0.851	0.858	0.855

表3实验结果说明以仅做特征简单拼接的Simple Concat为基线，完整模型在Weibo、Weibo21、PHEME三个数据集的F1值分别提升3.4、3.1、3.6个百分点，验证了双线性交互、跨注意力与门控融合机制的有效性。该架构突破了简单拼接的模式信息交互瓶颈，是模型性能提升的最主要来源。在简单拼接后单独叠加Transformer语义编码器，仅在同源的Weibo数据集上获得小幅性能增益；在分布异质性更强的PHEME数据集上，性能反而出现回落。这表明孤立的高层语义建模难以适配复杂跨域场景，其表征价值必须与多模态交互融合架构协同才能充分释放。与仅使用交叉熵分类损失的CE Only变体相比，完整模型的联合损失函数在所有数据集上均带来稳定性提升，且在数据分布较为复杂的PHEME数据集上增益最为突出，F1值提升8.1个百分点。该结果说明定制化的损失设计可有效增强特征判别性，大幅提升模型跨场景的泛化适配能力。综上，三类组件具备协同增益效应，各模块设计均具备必要性，共同支撑了MBSC-Net的最优检测性能。

4.7 可视化分析

为直观展示各组件对特征空间的渐进改善，本文使用t-SNE算法[46]对Weibo、Weibo21和PHEME测试集进行二维可视化，从左至右依次为：原始特征、简单拼接特征、以及完整MBSC-Net特征。






图2 MBSC-Net特征可视化图

图2从左至右呈现了从原始特征到完整MBSC-Net特征的渐进改善过程。完整模型在三个数据集上均形成了分离良好、紧凑的类别聚类。t-SNE可视化清晰地展示了从原始特征到完整模型特征的逐步改进过程。原始特征图2(a)、(d)、(g)显示两类样本严重混杂。简单拼接已经表现出一定的分离趋势，但仍存在边界模糊区域。完整MBSC-Net模型的特征形成了清晰的类间分离和紧凑的类内聚集，直观验证了互补多分支融合与多目标对比优化的协同效果。

4.7 计算效率分析

MBSC-Net与基线模型的计算效率比较。参数量仅统计可训练参数，FLOPs和延迟以单样本推理计量(V100 GPU,batch size=1)。

表4 计算效率分析表

模型	可训练参数(M)	FLOPs(G)	推理延迟(ms)	Weibo21 F1
EANN	23.70	95.80	23.79	0.920
SpotFake	23.17	95.80	23.77	0.913
SAFE	23.17	95.80	23.99	0.923
HMCAN	23.69	95.80	24.28	0.934
MDFEND	30.91	95.81	26.35	0.932
BMR	38.14	95.83	27.47	0.913
MMDFND	47.34	95.86	29.96	0.928
C3N	22.48	95.85	24.65	0.909
MBSC-Net	36.60	95.82	27.84	0.948

由表4的实验结果可知，MBSC-Net的浮点运算量为95.82G，与所有对比基线基本持平，说明所提多模态交互融合模块未引入显著的额外计算开销，核心运算复杂

度未发生量级性增长，计算复杂度与基线保持同量级，推理开销处于合理区间。在仅带来小幅时延增长的前提下，模型F1值较性能次优的HMCAN提升1.4个百分点，以有限的效率代价换取了检测性能的明显增益，兼顾了检测精度与推理实用性，精度与效率权衡优势显著。

4.8 组件交互效应

为严格验证分类损失与有监督对比损失的最优权重配置，在{0.0,0.1,0.2,0.3,0.4,0.5,0.6,0.7,0.8,0.9}范围内对 λ_{CE} 和 λ_{CONT} 开展9组网格搜索实验，结果如表5所示，本文采用的默认配置(0.6,0.4)以粗体标出。

表5 损失权重敏感性分析

Config	λ_{CE}	λ_{CONT}	F1			
			Weibo	Weibo21	PHEME	AVE
A0.1_C0.9	0.1	0.9	0.948	0.928	0.809	0.895
A0.2_C0.8	0.2	0.8	0.944	0.931	0.787	0.887
A0.3_C0.7	0.3	0.7	0.944	0.936	0.839	0.906
A0.4_C0.6	0.4	0.6	0.937	0.941	0.811	0.896
A0.5_C0.5	0.5	0.5	0.947	0.929	0.769	0.882
A0.6_C0.4	0.6	0.4	0.951	0.948	0.855	0.918
A0.7_C0.3	0.7	0.3	0.944	0.938	0.820	0.901
A0.8_C0.2	0.8	0.2	0.938	0.943	0.832	0.904
A0.9_C0.1	0.9	0.1	0.945	0.943	0.812	0.900

由表5的实验结果可知，默认配置实现全局最优性能，当 $\lambda_{CE}=0.6$ 、 $\lambda_{CONT}=0.4$ 时，模型在Weibo、Weibo21、PHEME三个数据集及平均F1指标上均取得最优值。该结果验证了分类损失主导、对比损失辅助的配比合理性，二者协同优化类别判别能力与类内特征聚合度，达成检测性能的最佳平衡。权重失衡会引发性能衰减，对比损失权重过高会弱化分类任务的核心引导作用，权重过低则无法充分发挥度量学习的正则化增益，二者均会导致模型性能持续下滑，证明两类损失需维持均衡配比以释放协同效应。最优配比具备跨域鲁棒性，在数据分布差异显著的三个数据集中，性能最优的权重区间均稳定落在 $\lambda_{CE} \in [0.5,0.7]$ 、 $\lambda_{CONT} \in [0.3,0.5]$ 范围，说明该损失组合的适配性强，无需针对特定数据集单独调参即可取得优异表现。

4.9 梯度冲突分析

为验证两个损失函数联合优化的可行性，对训练过程中各损失梯度在工作参数空间中的交互关系进行了分析。具体而言，在每个训练步骤中分别计算 ∇L_{CE} 、和 ∇L_{CONT} 对共享参数(融合管道参数 θ_{fusion})的梯度，并计算两两之间的余弦相似度，选用Weibo21数据集训练前10轮的平均值±标准差

表6 两类损失函数的成对梯度余弦相似度

损失对	融合管道参数	分类头参数
$L_{CE} \text{ vs } L_{CONT}$	0.09 ± 0.06	0.05 ± 0.02

表6的结果表明，两类损失函数的成对梯度余弦相似度低于0.15，远低于PCGrad中定义的梯度冲突阈值(余弦相似度<-0.5)。低正相似度表明各损失的梯度方向在参数空间中近似正交，各损失函数优化的是特征空间的不同方面，而非互相抵触的目标。这为式(18)中两个损失的直接加权求和提供了实验支撑：不存在有害的梯度抵消，

辅助损失的梯度为优化过程引入了有益的多样性扰动[47]。进一步分析揭示了两类损失在参数空间中的功能分工是 L_{CE} 的梯度主导分类头参数， L_{CONT} 的梯度集中于投影头参数，两者在融合管道参数上有轻微共享但无冲突。

4.10 门控权重可解释性分析




图3 门控权重分析图

本实验基于Weibo21测试集，分析MBSC-Net的门控权重分布，揭示其多模态虚假新闻检测的作用机制。从模态门控 α_1 来看，真实新闻的图像模态权重高度集中于0.95~1.0区间，虚假新闻分布在0.7~0.98区间且整体显著偏低。模型对图文一致的真实内容更依赖图像信息，对图文失配的虚假内容会主动弱化不可信图像的贡献，单模态门控已具备初步真伪区分能力。从交叉注意力门控 α_2 来看，真实样本权重聚集于0~0.1区间，几乎不激活跨模态交互；虚假样本呈两极分布，大量样本权重集中于0.6~0.8区间。虚假图文存在语义冲突时，模型会自适应提升交叉注意力权重，通过细粒度跨模态对齐捕捉不一致线索，强化虚假特征识别。 α_1 与 α_2 呈显著负相关，真伪样本在二维特征空间形成无重叠聚类；全局门控 $\beta=0.4877$ ，以基础门控为主通路保障效率，交叉注意力为动态补充。综上，分层门控机制可自适应匹配虚假新闻图文异构特性，验证了MBSC-Net门控设计的合理性与检测有效性。

5 结论

本文针对社交媒体虚假新闻检测中多模态细粒度交互建模不足的问题，提出了MBSC-Net互补多分支语义对比网络。MBSC-Net的核心贡献在于构建了由双线性融合、跨模态投影注意力与级联自适应模态门控组成的互补三支融合架构，从乘性二

阶交互、语义激活对齐和动态模态均衡三个维度全面捕捉跨模态关系。融合后的特征经轻量级Transformer语义编码器进行深层上下文精炼，并通过联合优化分类损失和有监督对比损失的多目标训练框架进行学习。在Weibo、Weibo21和Pheme三个公开数据集上的综合实验表明，MBSC-Net在F1分数等多项评估指标上超越了2018–2025年间八种主流基线模型。详细的消融研究验证了每个架构组件的贡献。t-SNE可视化直观地证实了所学表示的判别质量。结果表明，MBSC-Net该能较为优秀的解决上述问题。

虽然MBSC-Net在多模态虚假新闻检测任务中取得了良好结果，但仍存在一些局限性需要在未来工作中进一步探索。首先是本文的视觉编码器在训练保持完全冻结，可以采用轻量级部分微调策略探索参数高效微调策略(如LoRA[48]、Adapter[49])，提高社交媒体特有的虚假新闻视觉线索捕捉能力。此外，由于MBSC-Net是纯内容驱动的多模态检测框架，对事实检测覆盖较少，下一步计划引入外部知识源(如事实核查数据库[50]、知识图谱[51])可以在表面跨模态模式匹配之外，增强模型的事实性验证能力。

参考文献

- [1] Yadav S, Kesharwani A, Sharma D. Blurred Boundaries of Truth: A review of deepfakes and fake news[J]. Journal of Internet Commerce, 2026, 25(2): 240-262.
- [2] Boudana S, Segev E. Fake news makes the news: Definitions and framing of fake news in mainstream media[J]. Journalism Practice, 2026, 20(2): 679-698.
- [3] Zhang Y, Cheng T, Zhu L, et al. Evf-sam: Early vision-language fusion for text-prompted segment anything model[J]. Image and Vision Computing, 2026, 173: 106028.
- [4] Fu X, Zhang Z, Sun Y, et al. Dual-Branch Hybrid Visual Networks and Hierarchical Adaptive Fusion Strategy: An Effective Multimodal Fake News Detection Model[J]. The European Journal on Artificial Intelligence, 2025, 38(4): 543-561.
- [5] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers). 2019: 4171-4186.
- [6] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C]//International conference on machine learning. PmLR, 2021: 8748-8763.
- [7] Wang Y, Ma F, Jin Z, et al. Eann: Event adversarial neural networks for multi-modal fake news detection[C]//Proceedings of the 24th acm sigkdd international conference on knowledge discovery & data mining. 2018: 849-857.
- [8] Zhou X, Wu J, Zafarani R. : Similarity-aware multi-modal fake news detection[C]//Pacific-Asia Conference on knowledge discovery and data mining. Cham: Springer International Publishing, 2020: 354-367.
- [9] Qian S, Wang J, Hu J, et al. Hierarchical multi-modal contextual attention network for fake news detection[C]//Proceedings of the 44th international ACM SIGIR conference on research and development in information retrieval. 2021: 153-162.

- [10] Cui X, Zhang L. MTMixer: a hybrid Mamba-Transformer architecture for multimodal remote sensing image classification[J]. *International Journal of Remote Sensing*, 2026, 47(2): 770-799.
- [11] Jian C, Yin Z, Zhang Y, et al. A physics-informed generalization framework for cross-condition bearing fault diagnosis with limited labeled data[J]. *Information Sciences*, 2026: 123252.
- [12] Chandra M A, Bedi S S. Survey on SVM and their application in image classification[J]. *International Journal of Information Technology*, 2021, 13(5): 1-11.
- [13] Hu L, Jiang M, Liu X, et al. Significance-based decision tree for interpretable categorical data clustering[J]. *Information Sciences*, 2025, 690: 121588.
- [14] Sherstinsky A. Fundamentals of recurrent neural network (RNN) and long short-term memory (LSTM) network[J]. *Physica d: Nonlinear phenomena*, 2020, 404: 132306.
- [15] Alzubaidi L, Zhang J, Humaidi A J, et al. Review of deep learning: concepts, CNN architectures, challenges, applications, future directions[J]. *Journal of big Data*, 2021, 8(1): 53.
- [16] Cheruku R, Hussain K, Kavati I, et al. Sentiment classification with modified RoBERTa and recurrent neural networks[J]. *Multimedia Tools and Applications*, 2024, 83(10): 29399-29417.
- [17] Shu K. Application of the BERT and TextCNN Fusion Model in Chinese Sentiment Classification[C]//*The World Conference on Intelligent and 3D Technologies*. Cham: Springer Nature Switzerland, 2025: 39-56.
- [18] Sardi R M, Agustian S, Abdillah R, et al. Application of ensemble methods on transformer sequence classification of BERT base uncased and RoBERTa-base models for hate speech detection[J]. *Science, Technology, and Communication Journal*, 2026, 6(3): 431-440.
- [19] Singhal S, Shah R R, Chakraborty T, et al. Spotfake: A multi-modal framework for fake news detection[C]//*2019 IEEE fifth international conference on multimedia big data (BigMM)*. IEEE, 2019: 39-47.
- [20] Hamed S K, Ab Aziz M J, Yaakub M R. Enhanced feature representation for multimodal fake news detection using localized fine-tuning of improved BERT and VGG-19 models[J]. *Arabian Journal for Science and Engineering*, 2025, 50(10): 7423-7439.
- [21] Nan Q, Cao J, Zhu Y, et al. MDFEND: Multi-domain fake news detection[C]//*Proceedings of the 30th ACM international conference on information & knowledge management*. 2021: 3343-3347.
- [22] Ying Q, Hu X, Zhou Y, et al. Bootstrapping multi-view representations for fake news detection[C]//*Proceedings of the AAAI conference on Artificial Intelligence*. 2023, 37(4): 5384-5392.
- [23] Tong Y, Lu W, Zhao Z, et al. Mmdfnd: Multi-modal multi-domain fake news detection[C]//*Proceedings of the 32nd ACM International Conference on Multimedia*. 2024: 1178-1186.
- [24] Qiao J, Li X, Gao C, et al. Improving multimodal fake news detection by leveraging cross-modal content correlation[J]. *Information Processing & Management*, 2025, 62(5): 104120.
- [25] Zhang Z, Fu X, Wu T, et al. A Multimodal Fake News Detection Model Leveraging Image Frequency and Spatial Domain Analysis with Deep Dynamic Trade-Off Fusion[C]//*Chinese Conference on Pattern Recognition and Computer Vision (PRCV)*. Singapore: Springer Nature Singapore, 2024: 395-409.
- [26] Liu S, Quan W, Zhou M, et al. M2HF: Multi-branch multi-modal hybrid fusion for text-video retrieval[J]. *Computational Visual Media*, 2026.
- [27] Fukui A, Park D H, Yang D, et al. Multimodal compact bilinear pooling for visual question answering and visual grounding[C]//*Proceedings of the 2016 conference on empirical methods in natural language processing*. 2016: 457-468.

- [28] Geto A D, Emiru E D, Seid N E, et al. Multimodal based Amharic fake news detection using CNN and attention-based BiLSTM[J]. *Scientific Reports*, 2025, 15(1): 34447.
- [29] Yu Z, Yu J, Cui Y, et al. Deep modular co-attention networks for visual question answering[C]//*Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2019: 6281-6290.
- [30] Chen T, Kornblith S, Norouzi M, et al. A simple framework for contrastive learning of visual representations[C]//*International conference on machine learning*. PmLR, 2020: 1597-1607.
- [31] Yu T, Kumar S, Gupta A, et al. Gradient surgery for multi-task learning[J]. *Advances in neural information processing systems*, 2020, 33: 5824-5836.
- [32] Ji N, Sun Y, Meng F, et al. Variable multi-scale attention fusion network and adaptive correcting gradient optimization for multi-task learning[J]. *Pattern Recognition*, 2025, 162: 111423.
- [33] Jiang Y, Yu X, Wang Y, et al. Similarity-aware multimodal prompt learning for fake news detection[J]. *Information Sciences*, 2023, 647: 119446.
- [34] Liu Y, Bing W, Ren S, et al. BC-FND: an approach based on hierarchical bilinear fusion and multimodal consistency for fake news detection[J]. *IEEE Access*, 2024, 12: 62738-62749.
- [35] Ye H, Ge X, Wang J, et al. Beyond efficient fine-tuning: Efficient hybrid fine-tuning of CLIP models guided by explainable ViT attention[J]. *Information Processing & Management*, 2026, 63(4): 104628.
- [36] Brody S, Alon U, Yahav E. On the expressivity role of LayerNorm in transformers' attention[C]//*Findings of the Association for Computational Linguistics: ACL 2023*. 2023: 14211-14221.
- [37] Ahmed M R, Haque R, Rahman S M A, et al. Vision-audio multimodal object recognition using hybrid and tensor fusion techniques[J]. *Information Fusion*, 2025: 103667.
- [38] Yan T, Xing X, Wang D, et al. Interpretable degradation tensor modeling through multi-scale and multi-level time-frequency feature fusion for machine health monitoring[J]. *Information Fusion*, 2025, 117: 102935.
- [39] Guo Q, Qiu X, Liu P, et al. Multi-scale self-attention for text classification[C]//*Proceedings of the AAAI conference on artificial intelligence*. 2020, 34(05): 7847-7854.
- [40] Eldien N A S, Gomaa W H, Wassif K T, et al. Interpreting Multimodal Fake News Detection Models: An Experimental Study of Performance Factors and Modality Contributions[J]. *Interpreting*, 2026, 17(1).
- [41] He Z, Xiao Y. LPGNet: A Lightweight Network with Parallel Attention and Gated Fusion for Multimodal Emotion Recognition[J]. *Circuits, Systems, and Signal Processing*, 2026: 1-19.
- [42] Zhang Y, Zhang M, Wei B, et al. SparseMoE-MFN: A Sparse Attention and Mixture-of-Experts Framework for Multimodal Fake News Detection on Social Media[J]. *Computers, Materials, & Continua*, 2026, 87(2).
- [43] Srivastava N, Hinton G, Krizhevsky A, et al. Dropout: a simple way to prevent neural networks from overfitting[J]. *The journal of machine learning research*, 2014, 15(1): 1929-1958.
- [44] ZUBIAGA A, LIAKATA M, PROCTER R, et al. PHEME Rumour Scheme Dataset: Journalism Use Case[DB/OL]. (2016-02-01).[2026-04-24]. <https://doi.org/10.6084/m9.figshare.2068650>.
- [45] Huang Y. Pairwise T-Test: identification of tonal relations[C]//*2022 International Conference on Asian Language Processing (IALP)*. IEEE, 2022: 104-109.
- [46] Allaoui M, Belhaouari S B, Hedjam R, et al. t-SNE-PSO: Optimizing t-SNE using particle swarm optimization[J]. *Expert Systems with Applications*, 2025, 269: 126398.

- [47] Shi W, Chen Y, Bian S, et al. No loss, no gain: Gated refinement and adaptive compression for prompt optimization[J]. Advances in Neural Information Processing Systems, 2026, 38: 88191-88231.
- [48] Hu E J, Shen Y, Wallis P, et al. Lora: Low-rank adaptation of large language models[C]//International Conference on Learning Representations. Virtual Event: ICLR .2022.1(2): 3.
- [49] Lion K, Zhang L, Li B, et al. PoLAR: Polar-decomposed low-rank adapter representation[J]. Advances in Neural Information Processing Systems, 2026, 38: 149313-149358.
- [50] Fagbenro M, Washer C, Chella P, et al. Improved multi-agent knowledge sharing system using knowledge graphs for news bias detection and fact-checking: M. Fagbenro et al[J]. Neural Computing and Applications, 2026, 38(6): 163.
- [51] Zhou X, Li S, Liu Y, et al. LLM-based domain-specific knowledge graph construction and hybrid retrieval-augmented generation[J]. Journal of Manufacturing Systems, 2026, 86: 1022-1038.